PROJET CYBERSÉCURITÉ

Analyse Big Data & Modélisation R

Traitement des logs d'attaques, détection d'anomalies, Machine Learning & simulations

Auteur : Adam | **Établissement :** ISEN Brest | **Dépôt GitHub :** Cyber-surveillance (R1 à R9)

PHASE 1 : BIG DATA & ANALYSE R

Vue d'Ensemble de la Phase Big Data

01. Fondations & EDA
Étapes R1 à R3

Nettoyage des logs, typage, premières visualisations et cartes de chaleur par protocole.

02. Spatio-Temporel
Étapes R4 & R5

Lissage par moyenne mobile sur 7 jours, saisonnalité et cartographie mondiale des hotspots.

03. Machine Learning
Étapes R6 & R7

Clustering K-Means, isolation des 5% d'outliers et classification prédictive via Random Forest.

04. Advanced Analytics
Étapes R8 & R9

Traitement NLP des payloads texte et simulation financière de risque Monte Carlo (VaR 95%).

PHASE 1 : BIG DATA & ANALYSE R

Étape R1 à R3 : Fondations, Nettoyage & EDA

Nettoyage structuré et premières corrélations

- Imputation et filtrage rigoureux des valeurs manquantes (NA).
- Normalisation des noms de colonnes via janitor::clean_names().
- Extraction de variables dérivées : heures, jours, niveaux de sévérité.
- Analyse de la répartition des protocoles (TCP, UDP, HTTP) et cartes de chaleur.

RÉSUMÉ TECHNIQUE

Livrable principal :
cybersecurity_attacks_cleaned.csv

Packages R clés :
tidyverse, lubridate, janitor, scales.

PHASE 1 : BIG DATA & ANALYSE R

Étape R4 : Analyse Temporelle & Tendances

Lissage de tendance et motifs hebdomadaires

- Agrégation journalière du volume total d'incidents.
- Lissage par Moyenne Mobile (7 jours) avec le package zoo.
- Découplage des variations quotidiennes pour dégager la tendance de fond.
- Comparaison de l'activité par jour de la semaine (Semaine vs Week-end).

RÉSUMÉ TECHNIQUE

Visuel produit :
tendances_temporelles.png

Apport Métier :
Permet au SOC d'anticiper les fenêtres d'attaques récurrentes.

PHASE 1 : BIG DATA & ANALYSE R

Étape R5 : Analyse Spatiale & Géolocalisation

Cartographie des Hotspots de menaces

- Détection automatique de la colonne géographique (Pays / IP / Localisation).
- Extraction du Top 10 des zones émettrices ou ciblées.
- Cartographie mondiale interactive ou statique (maps).
- Représentation des événements selon le niveau de sévérité.

RÉSUMÉ TECHNIQUE

Visuel produit :
analyse_spatiale.png

Apport Métier :
Orientation des règles de filtrage géographique sur les pare-feu.

PHASE 1 : BIG DATA & ANALYSE R

Étape R6 : Clustering K-Means & Anomalies

Segmentation non supervisée & isolation d'outliers

- Normalisation centrée-réduite des variables numériques (scale).
- Groupement automatique en 3 clusters distincts via K-Means.
- Calcul de la distance euclidienne de chaque point à son centroïde.
- Isolation des 5% de points les plus éloignés comme 'Anomalies'.

RÉSUMÉ TECHNIQUE

Visuel produit :
clustering_anomalies.png

Apport Métier :
Mise en lumière d'attaques complexes non étiquetées.

PHASE 1 : BIG DATA & ANALYSE R

Étape R7 : Modélisation Prédictive (Random Forest)

Classification de sévérité en apprentissage supervisé

- Partitionnement des données : 80% Entraînement / 20% Test (caret).
- Entraînement d'un modèle d'ensemble Random Forest (100 arbres).
- Évaluation de la précision (Accuracy) sur la matrice de confusion.
- Classement de l'importance des variables par le score de Gini.

RÉSUMÉ TECHNIQUE

Visuel produit :
modelisation_importance_variables.png

Apport Métier :
Triage automatique de la priorité des alertes.

PHASE 1 : BIG DATA & ANALYSE R

Étape R8 & R9 : Advanced Analytics & Monte Carlo

NLP sur Payloads & Quantification financière du risque

• NLP (R8) : Tokenisation des payloads texte, retrait des stop-words et extraction des signatures malveillantes.

• Monte Carlo (R9) : 1 000 simulations probabilistes sur 30 jours.

• Combinaison des distributions de Poisson, Binomiale et Normale.

• Calcul de la valeur médiane du risque et de la Value at Risk (VaR 95%).

RÉSUMÉ TECHNIQUE

Visuels produits :
analyse_nlp_payloads.png
simulation_monte_carlo.png

Apport Métier :
Traduction du risque technique en k€ pour la direction.

PHASE 1 : BIG DATA & ANALYSE R

Bilan de la Phase 1 & Roadmap

LIVRABLES COMPLÉTÉS (R1 - R9)

✓ Pipeline R propre, modulaire et documenté

✓ 7 visuels graphiques haute définition (300 DPI)

✓ Modèle prédictif Random Forest opérationnel

✓ Moteur de simulation financière de risques Monte Carlo

✓ Code entièrement hébergé sur GitHub (Cyber-surveillance)

PROCHAINES ÉTAPES (PHASES 2 & 3)

➔ Phase 2 : Exposition des modèles via API REST (Flask/FastAPI)

➔ Phase 2 : Expliquabilité des modèles avec SHAP / LIME

➔ Phase 3 : Dashboard Live interactif en temps réel (R Shiny / Web)

➔ Phase 3 : Déploiement MLOps et automatisation des alertes